

1.

$$P\{Yf(x) < 0\}$$

$$= E[P(Y) \mathbb{1}\{Yf(x) < 0\} | X=x]$$

$$= E[P(Y=1)P(Y=1|X=x) \mathbb{1}\{f(x) < 0\}$$

LOTP

$$+ P(Y=-1)P(Y=-1|X=x) \mathbb{1}\{f(x) > 0\}]$$

$$= E[(1-\pi)p(x) \mathbb{1}\{f(x) < 0\} + \pi(1-p(x)) \mathbb{1}\{f(x) > 0\}]$$

$$= E[(1-\pi)p(x) \mathbb{1}\{f(x) < 0\}] + E[\pi(1-p(x)) \mathbb{1}\{f(x) > 0\}]$$

$$= E[(1-\pi)p(x) \mathbb{1}\{f(x) \leq 0\}] + E[\pi(1-p(x)) \mathbb{1}\{f(x) \geq 0\}]$$

위 식을 최소화하는  $f(x)$ 의 조건은

$$\begin{cases} f(x) < 0 & \text{if } (1-\pi)p(x) < \pi(1-p(x)) \\ f(x) = 0 & \text{if } (1-\pi)p(x) = \pi(1-p(x)) \\ f(x) > 0 & \text{if } (1-\pi)p(x) > \pi(1-p(x)) \end{cases}$$

$$\Leftrightarrow \begin{cases} f(x) < 0 & \text{if } p(x) < \pi \\ f(x) = 0 & \text{if } p(x) = \pi \\ f(x) > 0 & \text{if } p(x) > \pi \end{cases}$$

$$\therefore \text{sign}\{f^*(x)\} = \begin{cases} -1 & \text{if } p(x) - \pi < 0 \\ 0 & \text{if } p(x) - \pi = 0 \\ 1 & \text{if } p(x) - \pi > 0 \end{cases}$$

$$\Leftrightarrow \text{sign}\{f^*(x)\} = \begin{cases} -1 & \text{if } \text{sign}\{p(x) - \pi\} = -1 \\ 0 & \text{if } \text{sign}\{p(x) - \pi\} = 0 \\ 1 & \text{if } \text{sign}\{p(x) - \pi\} = 1 \end{cases}$$

$$\therefore \text{sign}\{f^*(x)\} = \text{sign}\{p(x) - \pi\}$$

2.

(a)

$$L(\mu | X_1, \dots, X_n) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}(\chi_i - \mu)^2} \quad (\because X_i \text{'s are independent.})$$

$$= \left( \frac{1}{\sqrt{2\pi}} \right)^n \prod_{i=1}^n e^{-\frac{1}{2}(\chi_i - \mu)^2}$$

$$\log L = -\frac{n}{2} \log(2\pi) - \frac{1}{2} \sum_{i=1}^n (\chi_i - \mu)^2$$

$$\frac{\partial \log L}{\partial \mu} = \sum_{i=1}^n (\chi_i - \mu) \stackrel{\text{set}}{=} 0 \Rightarrow \frac{1}{n} \sum_{i=1}^n \chi_i = \mu$$

$$\frac{\partial^2 \log L}{\partial \mu^2} = -n < 0 \Rightarrow \log L: \text{concave}$$

$$\therefore \hat{\mu}^{\text{MLE}} = \frac{1}{n} \sum_{i=1}^n \chi_i = \bar{X}_n$$

(b)

$$P(-z_{0.025} \leq \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \leq z_{0.025}) = 0.95 \text{ or } 95\% \quad \bar{X}_n = 12, \sigma = 1, n = 100$$

$$\Rightarrow P\left(\bar{X}_n - z_{0.025} \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X}_n + z_{0.025} \frac{\sigma}{\sqrt{n}}\right) \\ \approx P\left(12 - 1.96 \times \frac{1}{10} \leq \mu \leq 12 + 1.96 \times \frac{1}{10}\right)$$

$$\therefore 95\% \text{ CI for } \mu: (11.804, 12.196)$$

(c)

$$\text{Prior } \pi(\mu) = \frac{1}{100\sqrt{2\pi}} e^{-\frac{1}{2} \cdot \frac{\mu^2}{100^2}}$$

$$\propto e^{-\frac{1}{2 \cdot 100^2} \cdot \mu^2}$$

$$\text{Likelihood } L(x|\mu) = \left( \frac{1}{\sqrt{2\pi}} \right)^n \prod_{i=1}^n e^{-\frac{1}{2}(x_i - \mu)^2}$$

$$\propto e^{-\frac{1}{2} \sum_{i=1}^n (x_i - \mu)^2} = e^{-\frac{1}{2} \left( \sum_{i=1}^n x_i^2 - 2\mu \sum_{i=1}^n x_i + n\mu^2 \right)}$$

$$\propto e^{-\frac{1}{2} (-2\mu n \bar{x}_n + n\mu^2)}$$

$$\text{Posterior } f(\mu|x_1, \dots, x_n) \propto L(x|\mu) \pi(\mu)$$

$$\propto e^{-\frac{1}{2 \cdot 100^2} \mu^2} \cdot e^{-\frac{1}{2} (-2\mu n \bar{x}_n + n\mu^2)}$$

$$= e^{-\frac{1}{2} \left( \frac{1}{100^2} + n \right) \mu^2 + n \bar{x}_n \mu}$$

$$\propto e^{-\frac{1}{2} \left( \frac{1}{100^2} + n \right) \left\{ \mu^2 - \frac{2n \bar{x}_n}{\left( \frac{1}{100^2} + n \right)} \mu + \frac{n^2 \bar{x}_n^2}{\left( \frac{1}{100^2} + n \right)^2} \right\}}$$

$$= e^{-\frac{1}{2} \left( \frac{1}{100^2} + n \right) \left( \mu - \frac{n \bar{x}_n}{\frac{1}{100^2} + n} \right)^2}$$

$$\Leftrightarrow \mu|x_1, \dots, x_n \sim N\left( \frac{n \bar{x}_n}{\frac{1}{100^2} + n}, \left( \frac{1}{100^2} + n \right)^{-1} \right)$$

$$(d) \quad P(-z_{0.025} \leq \frac{\mu - \frac{n \bar{x}_n}{\frac{1}{100^2} + n}}{\left( \frac{1}{100^2} + n \right)^{-\frac{1}{2}} / \sqrt{n}} \leq z_{0.025} | x_1, \dots, x_n) = 0.95 \text{ on } \bar{x}_n = 12, n = 100$$

$$\Rightarrow P(-1.96 \leq \frac{\mu - \frac{100 \times 12}{\frac{1}{100^2} + 100}}{\left( \frac{1}{100^2} + 100 \right)^{-\frac{1}{2}} / \sqrt{100}} \leq 1.96) \approx P(-1.96 \leq \frac{\mu - 12}{0.01} \leq 1.96)$$

$$= P(12 - 1.96 \times 0.01 \leq \mu \leq 12 + 1.96 \times 0.01)$$

$$\therefore 95\% \text{ Credible interval for } \mu: (11.9804, 12.0196)$$

3.

	Accuracy
Logistic Regression	0.8655
LASSO-penalized Logistic Regression	0.8930
Linear SVM	0.8870
Gaussian Kernel SVM	0.8715
Classification Tree	0.8715
Random Forest	0.8845
Logit Boosting	0.8685

LASSO-penalized Logistic Regression의 Accuracy가 가장 높다.

실험 이전에는 앙상블 모델의 성능이 더 높을 것으로 예상하였으나 실제로 보고된 실험 결과는 그렇지 않았다. 이러한 결과가 나온 이유는 Training set의 크기가 500으로, 앙상블 모델의 성능이 높게 나오기에는 충분한 크기의 Training set이 아니었기 때문이라고 추측할 수 있다.

앙상블 모델은 여러 개의 개별 모델의 예측을 결합하여 더 좋은 예측을 하기 위한 모델인데, 여기에서 얻을 수 있는 다양성을 활용하기 위해서는 각각의 개별 모델이 다른 샘플과 특징을 학습할 수 있도록 충분한 양의 데이터가 필요하다.

이러한 이유로 Training set이 작은 경우에는 단일 모델을 사용했을 때 더 좋은 성능이 보고될 수 있다.

Tuning을 진행한 Hyperparameter는 다음과 같다.

Logistic Regression: 없음

LASSO-penalized Logistic Regression: lambda

Linear SVM: C

Gaussian Kernel SVM: C, sigma

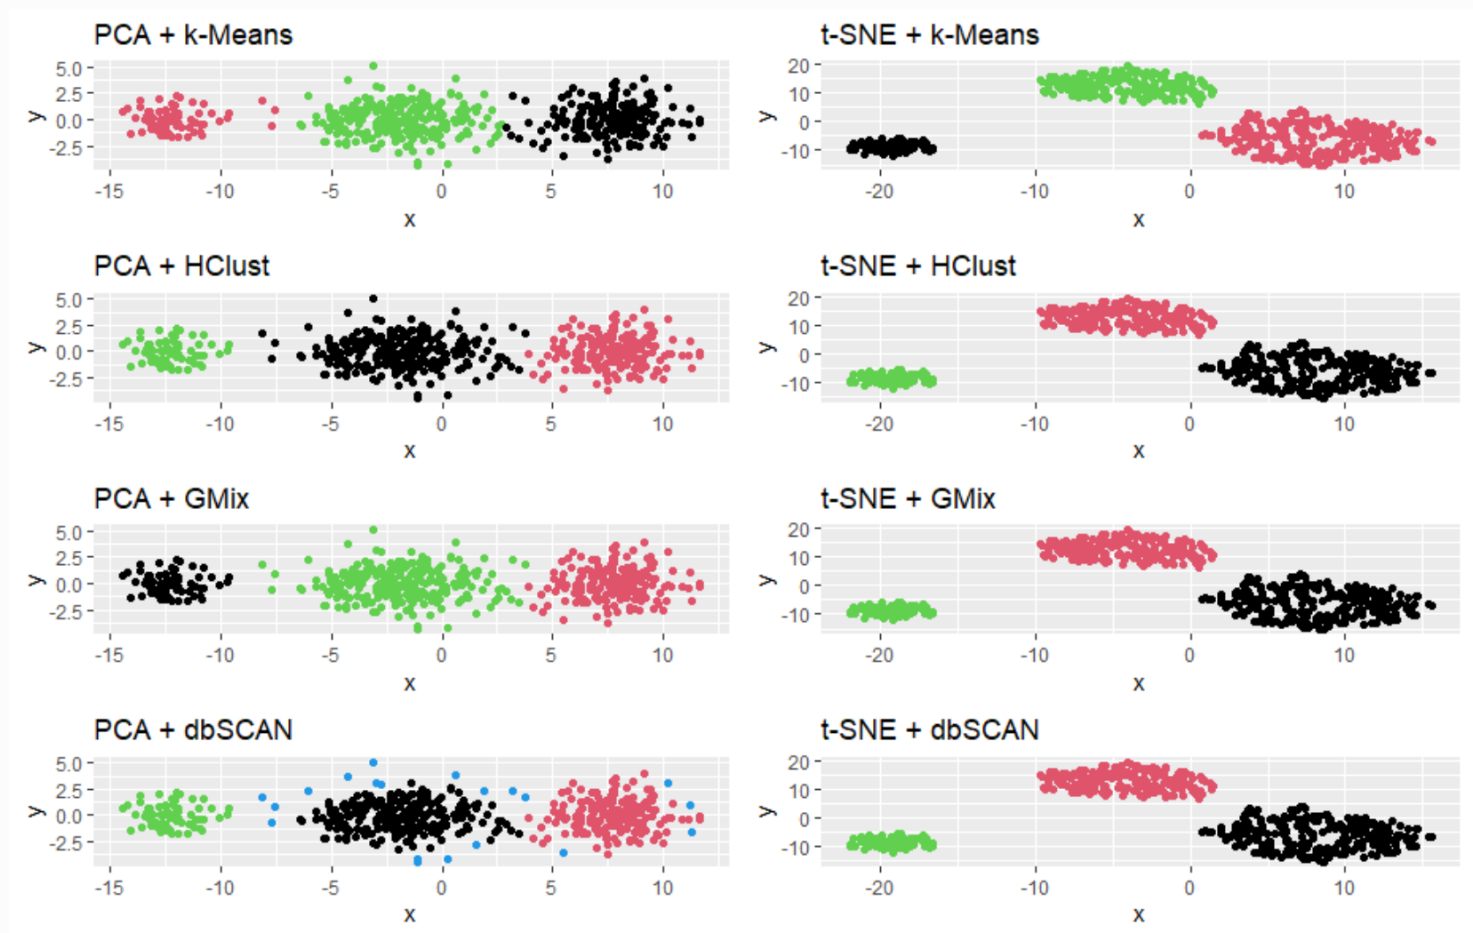
Classification Tree: size

Random Forest: mtry, ntree

Logit Boosting: n.trees

(STAT409\_Final\_2021320322.R에 과정 첨부)

4.



(STAT409\_Final\_2021320322.R에 과정 첨부)